

UAS KECERDASAN BUATAN · TEKNIK
ELEKTRO UB · 2025/2026

Prediksi Kelulusan Siswa

dengan Machine Learning

Pendekatan: Random Forest Classifier · Dataset: 500 Data Siswa Sintetis

Mata Kuliah
Kecerdasan Buatan

Dosen
Dr. Raden Arief Setyawan, ST.,
MT

Kelas / Prodi
C / Teknik Elektro S1

Dataset Sintetis Student Performance

500

Total Data Siswa

20

Fitur Input

2

Kelas Target

Contoh Fitur Dataset:

age — Usia siswa

studytime — Waktu belajar

absences — Jumlah absensi

failures — Kegagalan sebelumnya


Medu/Fedu — Pendidikan orang tua

famrel — Hub. keluarga

health — Kesehatan

internet — Akses internet

Alur Kerja Proyek



Preprocessing

- Label Encoding
- StandardScaler
- Split 80/20 stratified

Model

- Random Forest ★
- Decision Tree
- Logistic Regression

Evaluasi

- Accuracy Score
- Confusion Matrix
- ROC-AUC + 5-fold CV

Import Library yang Digunakan



```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')

from sklearn.model_selection import train_test_split,
    cross_val_score
from sklearn.preprocessing import LabelEncoder,
    StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score,
    confusion_matrix,
    classification_report, roc_auc_score, roc_curve
```

Pandas

Manipulasi & analisis data tabular (DataFrame)

NumPy

Operasi numerik dan array multi-dimensi

Matplotlib & Seaborn

Visualisasi data (grafik, heatmap)

Scikit-learn

Algoritma ML, preprocessing, dan evaluasi model

Pembuatan Dataset Sintetis



```
np.random.seed(42)
n = 500

df = pd.DataFrame({
    'age': np.random.randint(15, 22, n),
    'studytime': np.random.randint(1, 5, n),
    'failures': np.random.randint(0, 4, n),
    'absences': np.random.randint(0, 30, n),
    'Medu': np.random.randint(0, 5, n),
    ... # 20 fitur total
})

# Label kelulusan
df['pass'] = ((df['studytime']>=3) &
              (df['failures']==0) &
              (df['absences']<15) &
              (df['Medu']>=2)).astype(int)

# Tambah noise 15%
noise = np.random.random(n) < 0.15
```

Jumlah Data

500 siswa

Memenuhi syarat min.
300

Jumlah Fitur

20 fitur

Demografis + sosial +
akademik

Label Target

Biner

1 = Lulus, 0 = Tidak Lulus

Noise

15%

Agar data lebih realistis

Informasi & Statistik Dataset



```
print('=== INFO DATASET ===')
print(df.info())

print('=== STATISTIK DESKRIPTIF ===')
df.describe()
```

Output:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 500 entries, 0 to 499
Data columns (total 21 columns): ...
dtypes: int64(17), object(4)
```

df.info()

Menampilkan tipe data setiap kolom, jumlah entri non-null, dan penggunaan memori.

df.describe()

Menampilkan statistik deskriptif: mean, std, min, max, dan kuartil untuk kolom numerik.

Tujuan EDA

Memahami struktur data sebelum preprocessing agar tidak ada kesalahan dalam pengolahan.

Grafik Distribusi Data



```
plt.figure(figsize=(12, 4))

plt.subplot(1, 3, 1)
plt.bar(['Tidak Lulus', 'Lulus'], [counts[0], counts[1]],
        color=['#E74C3C', '#2ECC71'])
plt.title('Distribusi Label Kelulusan')

plt.subplot(1, 3, 2)
plt.hist(df['absences'], bins=20, color='steelblue')
plt.title('Distribusi Absensi')

plt.tight_layout()
plt.savefig('eda_distribusi.png', dpi=150)
plt.show()
```

Bar Chart

Distribusi label: ~71% Lulus, ~29% Tidak Lulus

Histogram

Distribusi absensi siswa (mayoritas 0–10 hari)




plt.savefig()

Grafik disimpan otomatis ke file .png untuk dokumentasi

Output File

eda_distribusi.png — dilampirkan di GitHub

Grafik Distribusi Data



Heatmap Korelasi Antar Fitur



```
numeric_cols =  
df.select_dtypes(include=[np.number]).columns  
plt.figure(figsize=(12, 8))  
  
corr = df[numeric_cols].corr()  
mask = np.triu(np.ones_like(corr, dtype=bool))  
  
sns.heatmap(corr, mask=mask, annot=True, fmt='.2f',  
            cmap='coolwarm', center=0, linewidths=0.5)  
  
plt.title('Heatmap Korelasi Fitur')  
plt.savefig('heatmap_korelasi.png', dpi=150)  
plt.show()
```

corr()

Menghitung matriks korelasi Pearson antar semua kolom numerik

mask=triu

Menyembunyikan segitiga atas agar tidak duplikat


annot=True

Menampilkan nilai korelasi di setiap sel heatmap

cmap coolwarm

Merah = korelasi positif, Biru = korelasi negatif

Heatmap Korelasi Antar Fitur



Encoding, Normalisasi & Split Data



```
# Label Encoding kolom kategorikal
df_enc = df.copy()
le = LabelEncoder()
for col in df_enc.select_dtypes('object').columns:
    df_enc[col] = le.fit_transform(df_enc[col])

# Pisah fitur dan target
X = df_enc.drop(columns=['pass'])
y = df_enc['pass']

# Split 80% train, 20% test (stratified)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# Normalisasi dengan StandardScaler
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc = scaler.transform(X_test)
```

Label Encoding

Mengubah kolom teks (sex, address, dll.) menjadi angka agar bisa diproses model ML.

train_test_split

Membagi 80% data untuk training dan 20% untuk testing. Stratify menjaga proporsi kelas.

StandardScaler

Normalisasi fitur: mean=0, std=1. Penting agar fitur dengan skala besar tidak mendominasi.

fit vs transform

fit_transform pada train, transform saja pada test — mencegah data leakage.

Melatih Tiga Model ML

```

models = {
    'Random Forest'      : RandomForestClassifier(
                           n_estimators=100,
                           random_state=42),
    'Decision Tree'      : DecisionTreeClassifier(
                           max_depth=5,
                           random_state=42),
    'Logistic Regression' : LogisticRegression(
                           max_iter=1000,
                           random_state=42)
}

results = {}
for name, model in models.items():
    model.fit(X_train_sc, y_train)
    y_pred = model.predict(X_test_sc)
    acc     = accuracy_score(y_test, y_pred)
    cv      = cross_val_score(model, X_train_sc,
                              y_train, cv=5)
    results[name] = {'model':model, 'y_pred':y_pred,
                    'accuracy':acc, 'cv_mean':cv.mean()}

```

Random Forest ★

Ensemble dari banyak Decision Tree. Tahan overfitting, akurasi tinggi.

Decision Tree

Model berbasis aturan if-else. Mudah diinterpretasi, cenderung overfit.

Logistic Regression

Model linier untuk klasifikasi biner. Cepat dan sebagai baseline.

5-fold Cross Val.

Validasi silang: data dibagi 5 bagian, model diuji 5 kali untuk stabilitas.

Grafik Perbandingan Akurasi Model



```
plt.figure(figsize=(9, 5))
b1 = plt.bar(x-0.18, accs, 0.35,
             label='Test Accuracy',
             color='#3498DB')
b2 = plt.bar(x+0.18, cvs, 0.35,
             yerr=stds, label='CV Accuracy',
             color='#E67E22', capsize=5)

plt.ylim(0.5, 1.0)
plt.title('Perbandingan Akurasi Model')
plt.savefig('perbandingan_model.png', dpi=150)
plt.show()
```

Test Accuracy

Akurasi pada data test (20% data yang tidak dilihat model saat training)

CV Accuracy

Rata-rata akurasi dari 5-fold cross validation pada data training


Error bar (yerr)

Menunjukkan standar deviasi CV — semakin kecil = semakin stabil

Kesimpulan

Random Forest terbaik: Test=0.78, CV=0.76 dengan gap kecil (tidak overfit)

Grafik Perbandingan Akurasi Model



Confusion Matrix Semua Model



```
fig, axes = plt.subplots(1, 3, figsize=(14, 4))

for ax, (name, res) in zip(axes, results.items()):
    cm = confusion_matrix(y_test, res['y_pred'])
    ConfusionMatrixDisplay(
        cm,
        display_labels=['Tidak Lulus', 'Lulus']
    ).plot(ax=ax, colorbar=False, cmap='Blues')
    ax.set_title(f'{name}\nAcc: {res["accuracy"]:.3f}')

plt.savefig('confusion_matrix.png', dpi=150)
plt.show()
```

TP (True Positive)

Diprediksi Lulus, memang Lulus

TN (True Negative)

Diprediksi Tidak Lulus, memang Tidak Lulus

FP (False Positive)




Diprediksi Lulus, padahal Tidak Lulus (Type I Error)

FN (False Negative)

Diprediksi Tidak Lulus, padahal Lulus (Type II Error)

Confusion Matrix Semua Model

Confusion Matrix - Semua Model



ROC Curve & AUC Score



```
plt.figure(figsize=(7, 6))

for (name, res), color in zip(results.items(),
    ['#3498DB', '#E67E22', '#2ECC71']):
    proba = res['model'].predict_proba(
        X_test_sc)[: ,1]
    fpr, tpr, _ = roc_curve(y_test, proba)
    auc = roc_auc_score(y_test, proba)
    plt.plot(fpr, tpr, lw=2,
        label=f'{name} (AUC={auc:.3f})')

plt.plot([0,1],[0,1], 'k--') # baseline
plt.savefig('roc_curve.png', dpi=150)
plt.show()
```

predict_proba()

Menghasilkan probabilitas setiap kelas, bukan hanya label 0/1

fpr & tpr

False Positive Rate vs True Positive Rate di berbagai threshold


AUC Score

Area Under Curve: semakin mendekati 1.0 = semakin baik model

k-- baseline

Garis diagonal = model acak (AUC=0.5), semua model harus di atasnya

ROC Curve & AUC Score



Fitur Terpenting (Random Forest)

```
rf = results['Random Forest']['model']
imp = pd.Series(
    rf.feature_importances_,
    index=X.columns
).sort_values(ascending=True).tail(15)

plt.barh(imp.index, imp.values,
color='#3498DB')
plt.title('Top 15 Fitur Terpenting')
plt.savefig('feature_importance.png', dpi=150)
plt.show()
```

feature_importances_

Atribut Random Forest yang menyimpan skor kepentingan setiap fitur (0–1, jumlah = 1)

Absensi (tertinggi)

Jumlah ketidakhadiran paling berpengaruh terhadap kelulusan siswa


Kegagalan sebelumnya

Riwayat kegagalan akademik adalah sinyal kuat prediksi tidak lulus

Waktu belajar

Semakin banyak waktu belajar = peluang lulus lebih tinggi

Fitur Terpenting (Random Forest)



Laporan Klasifikasi Model Terbaik



```
best = max(results, key=lambda x: results[x]['accuracy'])
print(f'=== CLASSIFICATION REPORT: {best} ===')
print(classification_report(
    y_test, results[best]['y_pred'],
    target_names=['Tidak Lulus', 'Lulus']
))
```

Output (estimasi):

	precision	recall	f1-score	support
Tidak Lulus	0.58	0.90	0.70	29
Lulus	0.94	0.74	0.83	71
accuracy			0.78	100

Precision

Dari semua diprediksi Lulus, berapa % yang benar-benar Lulus?

Recall

Dari semua siswa yang benar Lulus, berapa % yang berhasil terdeteksi?

F1-Score

Harmonic mean dari Precision & Recall — keseimbangan keduanya

Support

Jumlah data aktual per kelas dalam test set

Fungsi Prediksi Siswa Baru

```
def prediksi_siswa(data):
    df_in = pd.DataFrame([data])
    for col in X.columns:
        if col not in df_in.columns:
            df_in[col] = 0
    df_in = df_in[X.columns]
    scaled = scaler.transform(df_in)
    pred = rf.predict(scaled)[0]
    proba = rf.predict_proba(scaled)[0][1]
    print(f'Hasil : {"✓ LULUS" if pred==1 else "✗ TIDAK LULUS"}')
    print(f'Prob. : {proba:.1%}')

# Contoh penggunaan:
prediksi_siswa({
    'age':17, 'studytime':3, 'failures':0,
    'absences':3, 'health':4, 'Medu':3, ...
})
# Output: ✓ LULUS | Prob. 82.0%
```

pd.DataFrame([data])

Mengubah dict input menjadi DataFrame satu baris agar bisa diproses

scaler.transform()

Normalisasi input siswa menggunakan scaler yang sudah di-fit saat training

rf.predict()

Menghasilkan prediksi kelas: 0 (Tidak Lulus) atau 1 (Lulus)

predict_proba()[:,1]

Mengambil probabilitas kelas Lulus (indeks 1) dari output model

Ringkasan Hasil Proyek



```
print('='*55)
print('          RINGKASAN HASIL PROYEK')
print('='*55)
print(f'Dataset   : Sintetis Student Performance')
print(f'Jumlah Data : {len(df)} siswa')
print(f'Fitur       : {X.shape[1]} fitur')
print()
print('--- Performa Model ---')
for name, res in results.items():
    mark = '★' if name == best else ' '
    print(f'{mark} {name}: {res["accuracy"]:.4f}')
print()
print(f'✓ Model Terbaik : {best}')
print(f'✓ Akurasi Terbaik: {results[best]["accuracy"]*100:.2f}%')
print('='*55)
```

Output:

```
=====
          RINGKASAN HASIL
=====
Dataset       : Sintetis
Jumlah Data: 500 siswa
Fitur         : 20 fitur

--- Performa Model ---
★ Random Forest : 0.78
  Decision Tree : 0.73
  Logistic Reg. : 0.74

✓ Terbaik: Random Forest
✓ Akurasi: 78.00%
```